Sorbonne Université

Travaux d'étude et de recherche

Autour de l'analyse topologique des données

Auteure :
Hélène Authier

Sous la direction de :
Vincent Humilière

2 juin 2025

SCIENCES SORBONNE UNIVERSITÉ

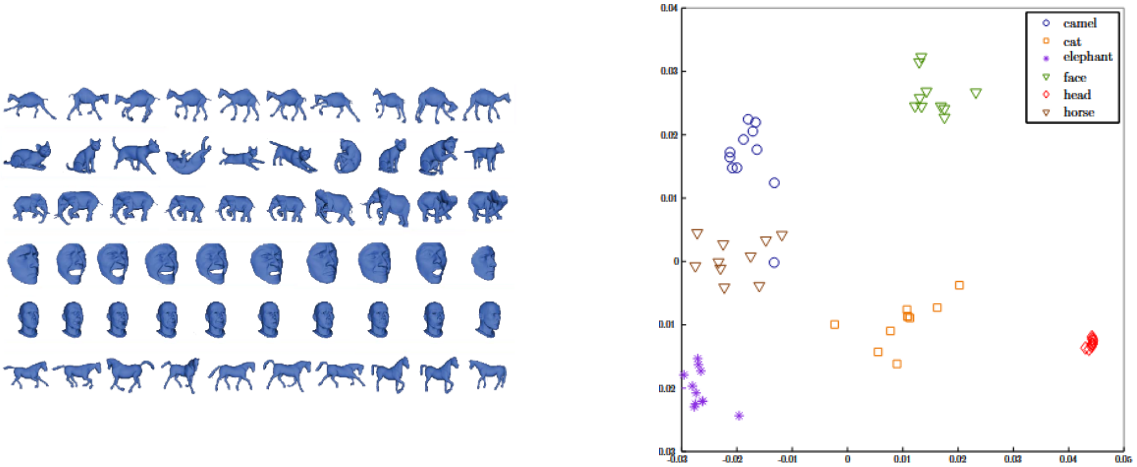
Table des matières

1 Introduction 2
2 Complexes simpliciaux 2
2.1 Définition et exemples 3
2.2 Réalisation topologique 3
2.3 Construction des complexes 4
2.4 Complexes de Čech et de Vietoris-Rips 5
3 Homologie simpliciale 5
4 Code-barres et Diagramme de persistance 7
4.1 Modules de persistance 7
4.2 Code-Barres 8
5 Calcul du code-barres et du diagramme de persistance 9
5.1 Construction de la paire persistante 10
5.2 Algorithme d'échelonnage des matrices 12
5.3 Construction du diagramme de persistance 14
6 Stabilité 16
6.1 La distance Bottleneck 16
6.2 La distance d'entrelacement 18
6.3 Théorème d'isométrie 18
7 Application et exemple : l'algorithme ToMATo 21
7.1 Problématique 21
7.2 L'algorithme ToMATo 21
7.3 Lien avec l'homologie en degré 0 23
8 Conclusion 24

1 Introduction

La reconnaissance et le classement des formes selon leur nature constituent une problématique centrale en science des données. Parmi les approches classiques, les méthodes spectrales, telles que la Shape DNA ou les Global Point Signatures, exploitent les valeurs propres du Laplacien-Beltrami pour capturer des invariants caractéristiques des formes.

Une autre voie, plus récente, est celle de l'analyse topologique des données (Topological Data Analysis, ou TDA), qui propose une lecture différente du problème. Dans leur article de 2009, "Gromov-Hausdorff Stable Signatures for Shapes using Persistence" [1], les auteurs introduisent une méthode fondée sur la persistance topologique afin de discriminer six catégories de formes. En définissant une distance adaptée, puis en construisant des filtrations sur ces données, ils appliquent l'homologie persistante pour obtenir des diagrammes qui distinguent nettement les six groupes. Pour comprendre les étapes de leur démarche, nous allons explorer le paysage de l'analyse topologique des données.



À gauche, la base de données pour les catégories, et à droite le diagramme représentant les différents regroupements de catégories. Les images proviennent de l'article [1].

Avant d'aborder les outils de l'analyse topologique, nous nous pencherons sur les complexes simpliciaux, des constructions géométriques simples à manipuler, qui jouent un rôle central en topologie algébrique.

2 Complexes simpliciaux

Cette section est motivée par l'idée de donner une explication intuitive et claire de l'homologie en prenant l'exemple de l'homologie sur des complexes simpliciaux. On suivra la structure du cours [2].

2.1 Définition et exemples

Définition : *(Combinatoire)* Un complexe simplicial est une paire (V, K) où V est un ensemble de sommets et K est un ensemble de parties non vides de V tel que :

— $V = \bigcup_{\sigma \in K} \sigma$

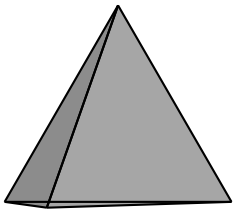
— Si $\sigma \in K$ et $\tau \subset \sigma$, alors $\tau \in K$

Les éléments $\sigma \in K$ sont appelés les simplexes.

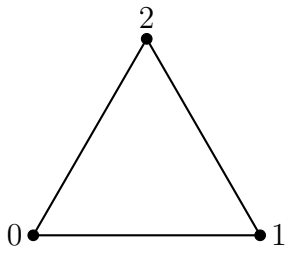
Définition : La dimension d'un simplexe $\sigma \in K$ est $\dim(\sigma) = \mathrm{Card}(\sigma) - 1$.
La dimension d'un complexe simplicial (V, K) vaut $\dim(V, K) = \sup_{\sigma \in K} \dim(\sigma)$.
Un simplexe maximal est un simplexe de dimension maximale dans le complexe.

Exemple 1 : Un complexe simplicial (V, K) de dimension 1 est un graphe.

Exemple 2 : *(Simplexe standard de dimension n)* Pour $n > 0$ un entier, on définit $V_n = \{0, \ldots, n\}$ et $\Delta^n = \mathcal{P}(V_n) \setminus \emptyset$.
Δ^1 est un segment, Δ^2 un triangle et Δ^3 un tétraèdre.

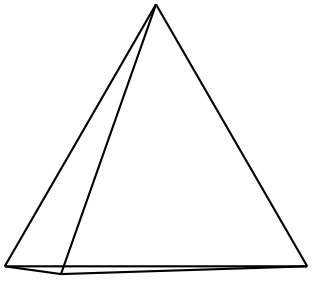


Δ^3



(V, K) avec $V = \{0, 1, 2\}$ et $K = \{\{0\}, \{1\}, \{2\}, \{0, 1\}, \{1, 2\}, \{0, 2\}\}$

Exemple 3 : *(Sphère simpliciale de dimension n-1)* Soit $n > 0$ un entier, soit V_n, et soit le simplexe maximal $\sigma_n = V_n$, alors $\mathbb{S}^{n-1} := \Delta^n \setminus \{\sigma_n\}$. Géométriquement, $\mathbb{S}^{n-1}$ est le bord de Δ^n.



$\mathbb{S}^2$: C'est une "sphère"

2.2 Réalisation topologique

Étant donné un complexe simplicial (V, K), sa réalisation topologique (notée $|K|$) est un espace topologique construit par recollement de simplexes, qui étendent en toute dimen-

sion la suite : segment, triangle, tétraèdre...

Définition : Soit un complexe simplicial (V, K) et soit l'espace vectoriel libre sur V noté $E = \mathbf{R}[V]$, alors $\forall \sigma \in K$ on note :

$$|\sigma| = \mathrm{Conv}(\sigma)$$

Et sa réalisation topologique de (V, K) est l'espace topologique :

$$|(V, K)| = \bigcup_{\sigma \in K} |\sigma|$$

2.3 Construction des complexes

Définition : Un complexe simplicial (V, K) est dit ordonné si V est muni d'une relation d'ordre, et si $\forall \sigma \in K$, σ est totalement ordonné.

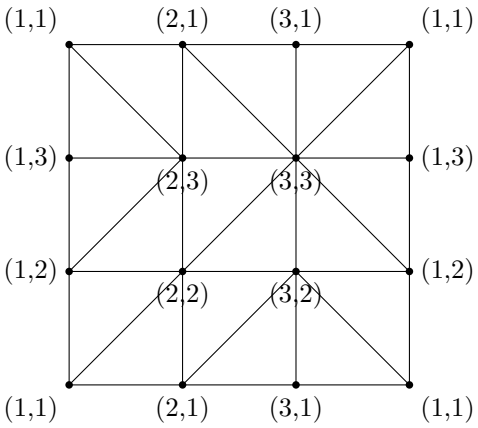
On induit un ordre sur le produit cartésien $V \times W$ qui est le suivant : $(p, q) \leq (p', q') \Leftrightarrow p \leq_V p'$ *et* $q \leq_W q'$.

Définition : *(produit cartésien)* Soient (V, K) et (W, L) deux complexes simpliciaux, alors leur produit cartésien est défini par :

- Ses sommets $V \times W$
- Ses simplexes $\sigma \subset V \times W$ tels que σ est totalement ordonné et tels que l'image de la projection $\sigma : V \times W \to V$ est un simplexe de K, et réciproquement pour W.

Exemple 1 : Le tore est défini comme le produit cartésien de deux sphères de dimension 1 :

$$\mathbb{T} = \mathbb{S}^1 \times \mathbb{S}^1$$



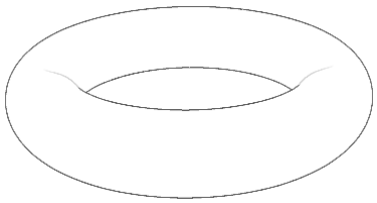


FIGURE 2 – Le Tore

Lemme : *(De recollement des complexes)* Soient (V, K) et (W, L) deux complexes simpliciaux avec σ_V et σ_W respectivement un simplexe maximal de K et L, avec $\dim \sigma_V = \dim \sigma_W$ et f une bijection entre leurs sommets. Alors on définit leur somme connexe $V \# W$ comme le complexe dont les simplexes sont les $\alpha \in K \setminus \{\sigma_V\}$ et les $\beta \in L \setminus \{\sigma_W\}$ et qu'on a recollé selon f.

Exemple 2 : Le tore de genre 2 est une somme connexe de deux tores : $\mathbb{T}\#\mathbb{T} = \mathbf{T}$.

2.4 Complexes de Čech et de Vietoris-Rips

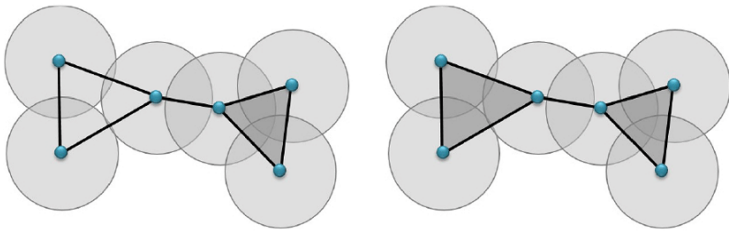
Définition : *(Complexe de Čech)* Soit (X, d) un espace métrique, et soit P un sous-ensemble fini de points de X. Soit $r > 0$. Le complexe de Čech $\mathbb{C}^r(P)$ est défini comme tel :

$$\mathbb{C}^r(P) = \{\sigma \subset P \mid \bigcap_{x \in \sigma} B(x, r) \neq \emptyset\}.$$

Définition : *(Complexe de Vietoris-Rips)* Soit (X, d), et soit P un sous-ensemble fini de points de X. Soit $r > 0$. Le complexe de Vietoris-Rips est défini comme tel :

$$\mathbb{VR}^r(P) = \{\sigma \subset P \mid d(p, q) \leq 2r, \forall\ p, q \text{ sommets de } \sigma\}.$$

Exemple : Un exemple de complexe de Čech (à gauche) et de complexe de Vietoris-Rips (à droite) sur un nuage de point pour un rayon r. Cette image a été trouvée dans [3].



3 Homologie simpliciale

Cadre : Par souci de simplicité, on considérera uniquement l'homologie sur $\mathbb{Z}/2\mathbb{Z}$.

Définition : Soit $\mathbf{F}_2$ l'anneau $\mathbb{Z}/2\mathbb{Z}$, soient (V, K) un complexe simplicial et n un entier. On définit $\mathcal{C}_n(K, \mathbf{F}_2)$ comme le $\mathbf{F}_2$-espace vectoriel sur l'ensemble des simplexes de K de dimension n. On le nomme espace des chaînes de degré n.

Définition : *(Opérateur bord)* On définit l'opérateur bord $\partial_n : C_n(K, \mathbb{F}_2) \to C_{n-1}(K, \mathbb{F}_2)$ comme ce qui suit :

$$\partial_n(\sigma) = \sum_{v \in \sigma} (\sigma \setminus \{v\}).$$

Exemples : Soit une arête $\{0, 1\}$, alors son bord est $\{0\} + \{1\}$.
Soit Δ^2, et soit le simplexe $\sigma = \{0, 1, 2\}$, alors son bord est $\{0, 1\} + \{0, 2\} + \{1, 2\}$.
C'est bien ce qu'intuitivement on entend par "bord".

Propriété : $\partial^2 = 0$. $\partial_{n-1} \circ \partial_n = 0$.

Définition : *(Cycles)* On appelle cycles les éléments de $\ker(\partial_n)$.
(Intuitivement, ce sont les "boucles", invariantes par déformations).

Propriété : L'ensemble des cycles est un sous-espace vectoriel de $\mathcal{C}_n(K, \mathbf{F}_2)$.

Propriété : $\mathrm{Im}(\partial_{n+1}) \subset \ker(\partial_n)$ et $\mathrm{Im}(\partial_{n+1})$ est un sous-groupe de $\ker(\partial_n)$.
Ainsi on peut quotienter les deux groupes entre eux et définir l'Homologie comme suivant :

Définition : *(Homologie simpliciale)* Le groupe d'Homologie de degré n est défini comme le groupe $\ker(\partial_n)$ quotienté par le groupe $\mathrm{Im}(\partial_{n+1})$. Soit :

$$H_n(K, \mathbf{F}_2) = \ker(\partial_n)/\mathrm{Im}(\partial_{n+1})$$

On constate intuitivement que les groupes d'homologie sont les groupes des cycles modulo les groupes des bords. Deux cycles sont dans la même classe d'équivalence si leur différence est un bord.

Exemple 1 : Soit le complexe $\mathbb{S}^1$, on cherche à déterminer son groupe d'Homologie de degré 1. $H_1(\mathbb{S}^1) = \ker(\partial_1)/\mathrm{Im}(\partial_2)$. On note que $H_1(\mathbb{S}^1) = \ker(\partial_1)$ car $\mathrm{Im}(\partial_2) = 0$ car il n'y a aucun cycle de dimension 2. Ainsi on calcule que la dimension du noyau $\ker(\partial_1)$ vaut 1, et donc, $H_1(\mathbb{S}^1) = \mathbb{Z}/2\mathbb{Z}$.

Exemple 2 : Soit le complexe Δ^2, qui est le même complexe que $\mathbb{S}^1$, mais avec le simplexe $\{0, 1, 2\}$ en plus. $H_1(\Delta^2) = \ker(\partial_1)/\mathrm{Im}(\partial_2)$. Ainsi, $\mathrm{Im}(\partial_2)$ est de dimension 1 car il y a en plus un bord de $\{0, 1, 2\}$ de dimension 1. Et donc $\ker(\partial_1) = \mathrm{Im}(\partial_2)$, ce qui nous donne $H_1(\Delta^2) = 0$.

Remarque : L'homologie en degré 0 correspond intuitivement au nombre de composantes connexes de la réalisation topologique du complexe. L'homologie en degré n correspond au nombre de "cavités" de dimension n.

Voici un critère pratique pour vérifier nos calculs d'homologie :

Théorème : *(Dualité de Poincaré)* Si V est un complexe simplicial dont la réalisation topologique est homéomorphe à une variété topologique compact, sans bord, orientée, de dimension n, alors $H_k(V) \simeq H_{n-k}(V) \quad \forall k \leq n$.

Proposition : Les groupes d'homologie de variétés ne dépendent pas de la décomposition simpliciale donnée.

Exemples : Les groupes d'homologie du tore sont les suivants :

$$H_n(\mathbb{T}) = \begin{cases} \mathbb{Z}/2\mathbb{Z} & n = 0 \\ (\mathbb{Z}/2\mathbb{Z})^2 & n = 1 \\ \mathbb{Z}/2\mathbb{Z} & n = 2 \end{cases} \quad \text{et 0 si } n \geq 3.$$

Et ceux du tore de genre 2 :

$$H_n(\mathbf{T}) = \begin{cases} \mathbb{Z}/2\mathbb{Z} & n = 0 \\ (\mathbb{Z}/2\mathbb{Z})^4 & n = 1 \\ \mathbb{Z}/2\mathbb{Z} & n = 2 \end{cases} \quad \text{et 0 si } n \geq 3.$$

Ces exemples illustrent la remarque et le théoreme précédent.

4 Code-barres et Diagramme de persistance

4.1 Modules de persistance

Définition : *(Filtration)* Une filtration d'espaces topologiques sur T est une famille d'espaces $(X_t)_{t\in T}$ telle que $X_t \subseteq X_{t'} \ \ \forall t \leq t'$.

Définition : *(Filtration des sous-niveaux)* Soit X un espace topologique et soit $f : X \to \mathbb{R}$ une fonction. Alors la famille $F_t = f^{-1}(]-\infty; t])$ est une filtration dans $\mathbb{R}$, appelée, filtration des sous-niveaux.

Définition : *(Filtration Simpliciale)* Une filtration est dite simpliciale lorsque $\forall t \in T,\ X_t$ est un complexe simplicial et X_t est un sous complexe de $X_{t'}$ $\forall t \leq t'$.

Définition : *(Module de persistance)* Soit $\mathbb{Z}$ un corps, et T un ensemble, un module (ou $\mathbb{Z}$-module) de persistance est une famille $(M_t)_{t\in T}$ de $\mathbb{Z}$-espaces vectoriels reliés par des applications $\mathbb{Z}$-linéaires $(m_{t,t'})_{t\leq t'}$ telles que :

$$\begin{cases} m_{t,t} = id_{M_t} \\ m_{t,t''} = m_{t',t''} \circ m_{t,t'} \quad \forall t \leq t' \leq t''. \end{cases}$$

Les espaces M_t et applications $m_{t,t'}$ sont nommés espaces internes et applications internes du module M.

Théorème : Soit $(X_t)_{t\in T}$ une filtration simpliciale, alors $\forall k$ degré d'homologie, la famille de groupes d'homologie $(H_k(X_t))_{t\in T}$, munis de leurs applications induites par les inclusions $h_{t,t'} : X_t \to X_{t'}$, forme un module de persistance.

Définition : *(Homologie persistante)* Soit $f : X \to \mathbb{R}$, alors si f est monotone et X est un complexe simplicial, alors la filtration des sous-niveaux de f est une filtration simpliciale. On note les applications internes du module induit en homologie $f_p^{i,j} : H_p(X_i) \to H_p(X_j)$ $\forall i \leq j$. Alors les groupes d'homologie persistante de degré p sont les images des morphismes $f_p^{i,j}$, c'est à dire $H_p^{i,j} = \mathrm{im} f_p^{i,j}$.

Remarque : On notera que l'homologie persistante est aussi définie pour les fonctions continues sur des complexes simpliciaux.

Définition : *(Somme directe)* Soient $(M_t)_{t\in T}$ et $(N_t)_{t\in T}$ deux modules de persistance, alors $(M \oplus N)_t = M_t \oplus N_t$ et $mn_{t,t'} = m_{t,t'} \oplus n_{t,t'}$, où $mn_{t,t'}$ sont les applications internes du module $M \oplus N$.

4.2 Code-Barres

Dans cette section on suppose T totalement ordonné, et les intervalles convexes pour l'ordre.
Définition : Soit un module M, alors s'il existe N et L, deux modules de persistance non-nuls tels que $M \simeq L \oplus N$, alors on dit que M est décomposable et L et N sont appelés les sommandes. Sinon, M est indécomposable.

Définition : *(Module intervalle)* Soit $I \subset T$ un intervalle. Le module intervalle $\mathbb{K}_I$ est défini comme suivant :
$(\mathbb{K}_I)_{t\in T} = \begin{cases} \mathbb{K} & \text{si } t \in I \\ 0 & \text{sinon.} \end{cases}$ avec les applications internes définies comme suivant :
$m_{t,t'} = \begin{cases} Id \text{ si } t, t' \in I \\ 0 \text{ sinon.} \end{cases}$

Théorème : Les modules intervalles sont indécomposables.

Démonstration : Soit $\mathbb{K}_I$ un module intervalle. Faisons une preuve par l'absurde. Si $I = \emptyset$ alors les sommandes seraient identiquement nulles. Si $I = \{a\}$, alors $(\mathbb{K}_I)_a = \mathbb{K}$ et $0 \to \mathbb{K}$ admet pour unique sommande $0 \to 0$ qui est nulle. Sinon, alors $\exists\ t < t'$ tel que $(\mathbb{K}_I)_t = (\mathbb{K}_I)_{t'} = \mathbb{K}$ et $\mathbb{K} \to \mathbb{K}$ admet comme unique sous-module non-nul $0 \to \mathbb{K}$ qui ne peut pas être une sommande car sinon la sommande supplémentaire serait isomorphe à $\mathbb{K} \to 0$ qui n'est pas une sommande car l'application qui envoie 0 sur $\mathbb{K}$ n'est pas un isomorphisme. Ainsi, le module intervalle $\mathbb{K}_I$ est indécomposable car sinon les portions $\mathbb{K} \to \mathbb{K}$ et $0 \to \mathbb{K}$ seraient décomposables.

Définition : *(q-tameness)* Un module de persistance est dit q-tame lorsque $\forall t < t'$ l'application interne $m_{t,t'}$ a une image de dimension finie.

Définition : Un module de persistance est dit pfd (pointwise finite dimensional) lorsque $\forall t \in T,\ \dim M_t < +\infty$.

Proposition : Un module pfd est q-tame : pfd $\Rightarrow$ q-tame.
En effet, un module pfd a en plus ses applications internes $m_{t,t}$ de rang fini.
S'ensuit un résultat général qui vaut pour tous les modules de persistance pfd mais pas pour les q-tame. Cependant on verra par la suite que l'on peut quand même travailler avec les modules q-tame :

Théorème : Tout module de persistance pfd $(M_t)_{t\in T}$ est décomposable en modules intervalles : $M \simeq \bigoplus_{I\in \mathbf{I}} M_I$.

Remarque : La preuve de ce résultat est donnée dans [7].

Remarque : Lorsque T est un ensemble fini, alors $(M_t)_{t\in T}$ est aussi décomposable en somme directe de modules intervalles.

Définition : *(Code-barres)* Soit $(M_t)_{t\in T}$ un module de persistance pfd, on définit son code-barres $B(M)$ comme le multiensemble (ensemble contenant des éléments avec leur multiplicité) des intervalles support des modules intervalles sommandes de M_t.

Définition : *(Diagramme de persistance)* Lorsque $T = \mathbb{R}$, le diagramme de persistance de $(M_t)_{t\in T}$ est le multiensemble $D(M)$ des paires (a, b) des extrémités des intervalles de $B(M)$ sur $\mathbb{R} \times \mathbb{R} \cup \{+\infty\}$.

Malgré le fait que les modules de persistance q-tame n'admettent pas de décomposition unique en modules intervalles, un résultat dû à [8] assure le fait suivant :
Théorème : Les modules de persistance q-tame ont un diagramme de persistance bien défini.

Remarque : Ainsi, pour une filtration simpliciale $(X_t)_{t\in T}$, son module de persistance en homologie $(H_k(X_t))_{t\in T}$ admet un code-barres si les groupes d'homologie sont de dimension finie. En particulier, pour le degré 0, $(H_0(X_t))_{t\in T}$ admet un code-barres si X_t a un nombre fini de composantes connexes $\forall t$.

Voici d'ailleurs un critère pratique :
Théorème : Soit X un polyhèdre (la réalisation topologique d'un complexe) compact et soit une fonction $f : X \to \mathbb{R}$ continue alors, l'homologie persistante $H(X_{sub})$ de la filtration des sous-niveaux de f est q-tame.
Elle admet donc un diagramme de persistance.

Théorème : Sur un espace métrique compact, les complexes de Vietoris-Rips et de Čech admettent un module de persistance induit en homologie q-tame.
Ce théorème est du [9].

Remarque : *(Interprétation des codes-barres)* Chaque intervalle (a, b) dans le code-barres représente une classe homologique qui naît en a et meurt en b. On en verra un exemple plus tard.

5 Calcul du code-barres et du diagramme de persistance

Cette section a été écrite à partir du livre "Computational topology for data analysis" [10], Section 3.2 et 3.3.

Dans cette section, on s'intéresse à une filtration simpliciale sur un complexe et on cherche à calculer son diagramme de persistance. Pour ceci on introduit des filtrations dites "simplexe par simplexe", et on cherche à apparier deux simplexes entre eux pour former une "paire persistante". L'idée est alors d'associer à notre complexe une matrice et de l'échelonner pour que le pivot de chaque colonne nous donne cette paire persistante.

Définition : Soit K un complexe simplicial. Une filtration "simplexe par simplexe" est une filtration simpliciale où : $\emptyset = K_0 \ \rightarrow ... \rightarrow K_n = K$ et où $K_j \setminus K_{j-1} = \sigma_j$.

Remarque : Pour simplifier les choses, on se ramène au cas où la dimension des simplexes insérés dans l'ordre dans la filtration est croissante.

Cadre : On se place dans $\mathbb{Z}/2\mathbb{Z}$.

5.1 Construction de la paire persistante

Associons maintenant des simplexes de la filtration en créant des "paires persistantes" qui encodent la vie et mort de classes d'homologie.

Proposition : Soit une filtration "simplexe par simplexe" et un simplexe σ_j de dimension p. Lorsque σ_j est inséré, il y a deux possibilités :
- Un p-cycle est créé. σ_j est alors un *simplexe positif*.
- Un $(p-1)$-cycle est détruit. σ_j est un *simplexe négatif*.

Démonstration : Soit $a_1 + a_2 + ... + a_n$ le bord de σ_j. Ainsi $\partial\sigma_j = a_1 + a_2 + ... + a_n$. Alors :
- Soit $a_1, a_2, ..., a_n$ est déjà un bord et il existe c tel que $\partial c = a_1 + a_2 + ... + a_n$, et ainsi $c + \sigma_j$ est un cycle, et σ_j crée un cycle.
- Soit $a_1, a_2, ..., a_n$ n'est pas déjà un bord, c'est donc un cycle et σ_j détruit le cycle.

On cherche maintenant à associer des simplexes positifs avec des simplexes négatifs.

Notations : *(Nombre de Betti)* Soit une filtration simpliciale dont les modules de persistances suivent le schéma suivant :

$$H_p\mathcal{F} : 0 = H_p(X_0) \rightarrow \cdots \rightarrow H_p(X_i) \rightarrow^{h_p^{i,j}} \cdots \rightarrow H_p(X_j) \cdots \rightarrow H_p(X_n) = H_p(X)$$

Alors on définit les nombres de Betti comme suivant : $\beta_p^{i,j} := \dim(H_p^{i,j})$ où
$H_p^{i,j} = Z_p(X_i)/(Z_p(X_i) \cap B_p(X_j))$ où $Z_p(X_i)$ et $B_p(X_j)$ sont respectivement le groupe des cycles de X_i et le groupe des bords de X_j de degré p.

Définition : *(Paires Persistantes)* Soit une filtration "simplexe par simplexe" $\mathcal{F} : K_0 \ \rightarrow ... \rightarrow K_n$ et soit σ_j un p-simplexe et σ_i un $(p-1)$-simplexe. Alors (σ_i, σ_j) forment une paire persistante, si et seulement si, le nombre de classes indépendantes crées à K_i et détruites à K_j est ≥ 1. Autrement dit, si et seulement si $\mu_p^{i,j} := (\beta_p^{i,j-1} - \beta_p^{i,j}) - (\beta_p^{i-1,j-1} - \beta_p^{i-1,j}) > 0$.

Remarque : Dans la définition de $\mu_p^{i,j}$, la première différence compte le nombre de classes créees avant X_i et détruites à X_j et la deuxième compte le nombre de classes qui existaient

avant X_i et détruites à X_j.

Processus d'appariement : Lorsque $\mu_p^{i,j} > 0$, $\forall p \in \mathbb{N}$, la destruction d'une classe est appariée de manière unique avec la création d'une classe selon "qui est la plus jeune". Par convention, un simplexe est plus jeune s'il arrive après dans la filtration. D'après notre proposition, cela revient à apparier des simplexes positifs avec des simplexes négatifs, de manière unique. Le procédé d'appariement est décrit ainsi :
On insère σ_j, un simplexe de dimension p, dans le complexe, et on observe :
Soit la classe $a_1+a_2+...+a_n := \partial\sigma_j$. Ce cycle $a_1+a_2+...+a_n$ a été créé quand le plus jeune simplexe σ_i de dimension $(p-1)$ a été ajouté à l'étape i, mettons, $\sigma_i = a_n$. Le simplexe σ_i est donc un simplexe positif. S'il a déjà été apparié avec σ'_j de dimension p, c'est qu'une autre classe de dimension $(p-1)$ a été créé par σ_i et a été détruite par σ'_j. Notons ce cycle $a_n + b_1 + b_2 + ... + b_m$. Alors le nouveau cycle $a_1 + a_2 + ... + a_{n-1} + b_1 + b_2 + ... + b_m$ existait avant σ_i. Alors on cherche de nouveau le plus jeune σ_i qui a créé le nouveau cycle en étant ajouté. On recommence alors l'étape jusqu'à ce qu'on tombe sur un σ_i non-apparié ou que le cycle soit vide. Alors soit :
- le cycle se met à jour jusqu'à devenir vide ; c'est que $a_1 + a_2 + ... + a_n := \partial\sigma_j$ était déjà un bord, et que donc σ_j créé un nouveau p-cycle ; σ_j est donc un simplexe positif et va être apparié plus tard.
- on finit par trouver un σ_i non-apparié, et σ_i est apparié avec σ_j, ils forment la paire (σ_i, σ_j).
Voici d'ailleurs le petit algorithme 1, qui crée des paires persistantes :

Entrée: $\sigma_1, ...\sigma_n$ des simplexes ordonnés dans une filtration simpliciale
Sortie : Détermine si les simplexes sont négatifs ou positif et donne les paires (σ_i, σ_j) persistantes

for *j de* 1 *à n* **do**
  c := $\partial_p\sigma_j$
  σ_i est le plus jeune $(p-1)$-simplexe positif dans c
  while *σ_i est apparié et c est non vide* **do**
    Soit c' le cycle détruit par $\sigma_{j'}$, le simplexe apparié avec σ_i
    c = c + c'
    σ_i devient le nouveau plus jeune $(p-1)$-simplexe positif dans c
  end
  if *c est non-vide* **then**
    σ_j est un p-simplexe négatif
    générer la paire (σ_i, σ_j)
  end
  else
    σ_j est un p-simplexe positif
  end
end
return (σ_i, σ_j)

Algorithme 1: Création des paires persistantes

5.2 Algorithme d'échelonnage des matrices

Cadre : On remarque que l'on peut représenter à partir d'un complexe (V, K) sa matrice B de l'opérateur bord, avec en colonne les p-simplexes et en lignes les $(p-1)$-simplexes de (V, K), que l'on définit comme ce qui suit :

- $B^p_{i,j} = \begin{cases} 1 \text{ si } \sigma_i \in \partial_p \sigma_j \\ 0 \text{ sinon} \end{cases}$

On peut regrouper toutes les B^p en une matrice B qui représente l'ensemble des applications linéaires $\bigoplus_p \partial_p = \bigoplus_p (C_p \to C_{p-1})$.

Définition : *(Matrice de l'opérateur bord filtrée)* Soit $\mathcal{F} : K_0 \to ... \to K_n = (V, K)$ une filtration "simplexe par simplexe", et $\sigma_1, ...\sigma_j$ les simplexes, rangés par ordre d'insertion. Alors la matrice D, notée matrice de l'opérateur bord filtrée, est la matrice qui tient compte de l'ordre des simplexes, i.e le simplexe σ_i est bien positionné à la ligne et la colonne i.

Notations : On note $\text{lign}_D[i]$, $\text{col}_D[j]$ et $\text{piv}_D[j]$, respectivement, la $i^{\text{ème}}$ ligne et la $j^{\text{ème}}$ colonne de D, et le pivot de la ligne j, c'est à dire l'indice de la ligne où il y a l'élément le plus bas non-nul de la colonne j. Notons que lorsque la colonne j est vide, $\text{piv}_D[j]$ est indéfini et vaut -1 dans l'algorithme 2.

Définition : *(Échelonnage de matrice)* Une matrice D est dite échelonnée si $\forall j' \neq j \in \{1, ..., n\},\ piv_D[j'] \neq piv_D[j]$.

Proposition : Dans une matrice échelonnée, toutes les colonnes non-nulles sont linéairement indépendantes.

Pour échelonner la matrice de l'opérateur bord D nous allons effectuer des additions sur les colonnes de gauche à droite, sans changer l'ordre des colonnes.

Voici l'algorithme 2 qui échelonne une matrice de l'opérateur bord filtrée (on notera qu'il a une complexité en $O(n^3)$) :

Entrée: Une matrice D de l'opérateur bord filtrée
Sortie : La matrice échelonnée, selon des additions sur les colonnes, sans changer l'ordre de celles-ci

for j *de* 1 *à* $|\ col_D\ |$ **do**
  while $\exists j' < j$ *tel que* $piv_D(j') == piv_D(j)$ *et* $piv_D(j) \neq -1$ **do**
    $col_D(j) = col_D(j) + col_D(j')$
  end
  if $piv_D(j) \neq -1$ **then**
    $i := piv_D(j)$; (génère la paire (σ_i, σ_j))
  end
end
return (σ_i, σ_j)

Algorithme 2: Échelonnage de matrice

Proposition : La matrice échelonnée R est de la forme $R = DV$ où D est la matrice de l'opérateur bord filtrée et V est une matrice triangulaire supérieure.
De plus, le pivot de chaque colonne de la matrice échelonnée, c'est à dire l'indice de ligne de l'élément le plus bas non nul, est unique, dans le sens où il ne dépend pas de l'échelonnage, si l'échelonnage est effectué de gauche à droite en additionnant les colonnes.

Notations : Soit $A \in \mathcal{M}_{n\times n}(\mathbb{Z}/2\mathbb{Z})$, on appelle A^i_j la matrice qui va des indices 1 à i et j à n. On définit alors $r_A(i,j) := (\text{rang}(A^j_i) - \text{rang}(A^j_{i+1})) + (\text{rang}(A^{j-1}_{i+1}) - \text{rang}(A^{j-1}_i))$.
On a alors :

Proposition : Soit R la matrice échelonnée telle que $R = DV$, alors $\forall j \in \{1, ...n\}$, $\text{piv}_R(j) = i$ si et seulement si $r_D(i,j) = 1$.
On va pouvoir ainsi exhiber des paires persistantes de simplexes σ_i et σ_j à partir des pivots de chaque colonne de manière unique, le théorème s'énonce ainsi :

Théorème : Soit une matrice D de l'opérateur bord filtrée de taille $n \times n$, et soit R sa matrice échelonnée telle que $R = DV$, avec V une matrice triangulaire supérieure. Alors si σ_i et σ_j forment une paire persistante si et seulement si $\text{piv}_R(j) = i$.

Démonstration : On remarque préliminairement que $r_D(i,j) = r_R(i,j)$ car $\text{rang}(D^j_i) = \text{rang}(R^j_i)$ et donc il suffit de démontrer que $r_R(i,j) = 1 \Leftrightarrow \sigma_i$ *et* σ_j forment une paire persistante. On choisira d'utiliser la caractérisation σ_i *et* σ_j forment une paire persistante $\Leftrightarrow \mu^{i,j}_p > 0$.
Puisque la proposition assure l'unicité du pivot, nous pouvons choisir n'importe quel échelonnage de gauche à droite sur les colonnes qui respecte $R = DV$. Par simplicité nous choisirons l'échelonnage donné par l'algorithme 2.
Soient D^p et R^p respectivement la matrice de l'opérateur bord filtrée pour la dimension p et la matrice échelonnée de dimension p. Alors l'algorithme échelonne chaque D^p indépendemment pour donner un R^p. Pour la suite on donne $p = \dim(\sigma_j)$ On admettra la proposition suivante :
Proposition : Soit σ_j et soit $R' = R^p$, alors $\forall i \in \{1, ..., j-1\}$, $r_R(i,j) = r_{R'}(i,j)$.
On travaille donc avec la matrice réduite aux simplexes de dimension p.

Soient Z^k_{p-1} et B^k_{p-1} respectivement le groupe des cycles, et le groupe des bords de degré $p-1$. Par définition,

$$\beta^{a,b}_{p-1} := \text{rang}(H^{a,b}_{p-1}) = \text{rang}\left(\frac{Z^a_{p-1}}{Z^a_{p-1} \cap B^b_{p-1}}\right) = \text{rang}(Z^a_{p-1}) \ - \ \text{rang}(Z^a_{p-1} \cap B^b_{p-1}).$$

Soit $\Gamma^b_a := \{\text{col}_{R'}[k] \mid k \in [1,b] \text{ et } 1 \leq \text{piv}_{R'}[k] \leq a\}$. En utilisant le fait que toutes les colonnes non nulles de R' d'indice inférieur ou égal à b forment une base de B^b_{p-1}, et que chaque indice de ligne minimale pour chaque colonne non nulle est unique, on peut montrer que :

$$\text{rang}(Z^a_{p-1} \cap B^b_{p-1}) = |\Gamma^b_a|.$$

Considérons maintenant l'ensemble des colonnes non nulles de R' d'indice au plus égal à b mais ne faisant pas partie de Γ^b_a, noté ${\Gamma'}^b_a$. On a alors :

$$|{\Gamma'}^b_a| = \text{rang}({R'}^b_{a+1}) = \text{rang}(B^b_{p-1}) - |\Gamma^b_a|,$$

donc :

$$\text{rang}(Z^a_{p-1} \cap B^b_{p-1}) = |\Gamma^b_a| = \text{rang}(B^b_{p-1}) - |{\Gamma'}^b_a| = \text{rang}({R'}^b_1) - \text{rang}({R'}^b_{a+1}).$$

Par la proposition on a :

$$\mu^{i,j}_{p-1} = \ \text{rang}(Z^i_{p-1}) - \text{rang}(Z^i_{p-1} \cap B^{j-1}_{p-1}) - (\text{rang}(Z^i_{p-1}) - \text{rang}(Z^i_{p-1} \cap B^j_{p-1}))$$

$$- \ (\text{rang}(\text{Z}^{i-1}_{p-1}) - \text{rang}(Z^{i-1}_{p-1} \cap B^{j-1}_{p-1})) + \text{rang}(Z^{i-1}_{p-1}) - \text{rang}(Z^{i-1}_{p-1} \cap B^j_{p-1})$$

$$= \ \text{rang}(Z^i_{p-1} \cap B^j_{p-1}) \ - \ \text{rang}(Z^i_{p-1} \cap B^{j-1}_{p-1}) \ + \ \text{rang}(Z^{i-1}_{p-1} \cap B^{j-1}_{p-1}) \ - \ \text{rang}(Z^{i-1}_{p-1} \cap B^j_{p-1})$$

$$= \ -\text{rang}(R'^j_{i+1}) + \text{rang}(R'^{j-1}_{i+1}) - \text{rang}(R'^{j-1}_i) + \text{rang}(R'^j_i) = r_{R'}(i,j) = r_R(i,j) = r_D(i,j).$$

Ce qui donne une égalité entre $\mu^{i,j}_{p-1}$ et $r_D(i,j)$, ce qui conclut la preuve. □

5.3 Construction du diagramme de persistance

Une fois l'algorithme exécuté sur notre filtration simpliciale "simplexe par simplexe", on obtient une matrice échelonnée dont on peut extraire les paires persistantes : chaque pivot situé à l'intersection d'une ligne i et d'une colonne j génère la paire (σ_i, σ_j) qui crée l'intervalle $[i,j[$ en degré d_i, la dimension de σ_i. Les simplexes σ_k non-appariés forment les paires $[k,+\infty[$ en degré d_k dans le code-barres. Le diagramme de persistance est créé à partir des paires du code-barres. On cherche à calculer le diagramme de persistance de la sphère, ce qui donne en complexe simplicial $\mathbb{S}^2$, soit le bord de Δ^3. On a astucieusement transformé ce complexe en filtration simpliciale où chaque simplexe est numéroté de 1 à 14 et s'insère dans un ordre croissant dans la filtration "simplexe par simplexe" :

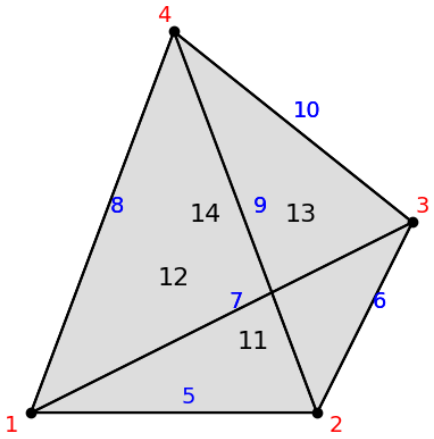


FIGURE 3 – $\mathbb{S}^2$ avec ses simplexes numérotés

On construit ensuite sa matrice de l'opérateur bord, et on échelonne la matrice selon l'algorithme :

$$\begin{bmatrix} 0&0&0&0&1&0&1&1&0&0&0&0&0&0\\ 0&0&0&0&1&1&0&0&1&0&0&0&0&0\\ 0&0&0&0&0&1&1&0&0&1&0&0&0&0\\ 0&0&0&0&0&0&0&1&1&1&0&0&0&0\\ 0&0&0&0&0&0&0&0&0&0&1&1&0&0\\ 0&0&0&0&0&0&0&0&0&0&1&0&1&0\\ 0&0&0&0&0&0&0&0&0&0&1&0&0&1\\ 0&0&0&0&0&0&0&0&0&0&0&1&0&1\\ 0&0&0&0&0&0&0&0&0&0&0&1&1&0\\ 0&0&0&0&0&0&0&0&0&0&0&0&1&1 \end{bmatrix}$$

Matrice de l'opérateur bord

$$\begin{bmatrix} 0&0&0&0&1&0&0&1&0&0&0&0&0&0\\ 0&0&0&0&\mathbf{1}&1&0&0&0&0&0&0&0&0\\ 0&0&0&0&0&\mathbf{1}&0&0&0&0&0&0&0&0\\ 0&0&0&0&0&0&0&\mathbf{1}&0&0&0&0&0&0\\ 0&0&0&0&0&0&0&0&0&0&1&1&0&0\\ 0&0&0&0&0&0&0&0&0&0&1&0&1&0\\ 0&0&0&0&0&0&0&0&0&0&\mathbf{1}&0&0&0\\ 0&0&0&0&0&0&0&0&0&0&0&1&0&0\\ 0&0&0&0&0&0&0&0&0&0&0&\mathbf{1}&1&0\\ 0&0&0&0&0&0&0&0&0&0&0&0&\mathbf{1}&0 \end{bmatrix}$$

Matrice échelonnée

On obtient donc les paires persistantes suivantes : $[2,5[$, $[3,6[$, $[4,8[$, $[7,11[$, $[9,12[$, $[10,13[$ respectivement de degré $0,0,0,1,1$ et 1. Les simplexes 1 et 14 n'étant pas appariés, ils créent les paires $[1,+\infty[$, $[14,+\infty[$, respectivement de degré 0 et 2. En effet, il y a une composante connexe introduite au simplexe 1 et le simplexe 14 vient créer un cycle de dimension 2. Les autres barres sont de longueur finies, en accord avec un groupe d'homologie nul pour le degré 1.
On a ensuite le diagramme de persistance suivant :

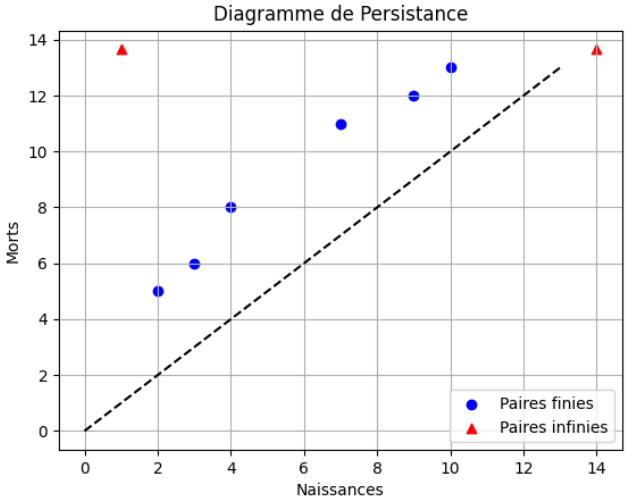


FIGURE 4 – Diagramme de persistance de notre filtration simpliciale

Interprétation : Notre complexe simplicial a pour réalisation topologique la sphère $\mathbb{S}^2$, regardons donc si le résultat obtenu est cohérent avec l'homologie de la sphère de dimension 2.

$$H_k(\mathbb{S}^2) = \begin{cases} \mathbb{Z}/2\mathbb{Z} \text{ si } k = 0 \\ \mathbb{Z}/2\mathbb{Z} \text{ si } k = 2 \\ 0 \quad \text{sinon} \end{cases}$$

On voit que une barre infinie est créée lorsque 1 apparaît, et de même lorsque 14, qui vient renfermer la sphère, apparaît. Les barres de longueur finie sont insignifiantes dans ce cas là.

6 Stabilité

Après avoir vu le calcul des diagrammes de persistance, nous allons nous intéresser aux théorèmes de stabilité, qui permettent, entre autres, de dire que de petites variations pour les fonctions, entraînent de petites variations sur les diagrammes de persistance issus des filtrations des sous-niveaux de f.

Cadre : Dans cette section, $T = \mathbb{R}$ et on s'intéresse aux diagrammes de cardinaux finis, dont les coordonnées sont elles aussi finies. De plus, on se place dans $\mathbb{Z}/2\mathbb{Z}$.
Cette section provient du livre "The structure and stability of persistence modules" [11].

6.1 La distance Bottleneck

Définition : *(Distance l^∞)* La distance l^∞ est définie comme telle : $d^\infty((a,b),(c,d)) = \max(|a-c|, |b-d|)$.

Propriété : $d^\infty((a,b),\Delta) = \frac{1}{2}(b-a)$ où Δ désigne la diagonale.

Remarque : Par mesure de simplicité, et pour se ramener a des ensembles, on suppose que le multiensemble A devient un ensemble en étiquetant la multiplicité k de α : $\alpha_1, \dots, \alpha_k$.

Définition : *(Correspondance partielle)* Une correspondance partielle C entre A et B est un sous-ensemble du produit cartésien $A \times B$ tel que :

- $\forall \alpha \in A$, il existe au plus un $\beta \in B$ tel que $(\alpha, \beta) \in M$.
- $\forall \beta \in B$, il existe au plus un $\alpha \in A$ tel que $(\alpha, \beta) \in M$.

Définition : *(δ-correspondance)* Une correspondance partielle est appelée δ-correspondance si, de plus :

- $(\alpha, \beta) \in M$ alors, $d^\infty(\alpha, \beta) \leq \delta$.
- $\alpha \in A$ n'est pas apparié (il n'a pas été associé dans la correspondance partielle) alors, $d^\infty(\alpha, \Delta) \leq \delta$..
- $\beta \in B$ n'est pas apparié alors, $d^\infty(\beta, \Delta) \leq \delta$.

Définition : *(Distance Bottleneck)* La distance Bottleneck entre deux diagrammes de persistance D et D' est définie comme telle :

$$d_B(D, D') = \{\inf \delta \mid \exists \text{ une } \delta\text{-correspondance entre } D \text{ et } D'\}.$$

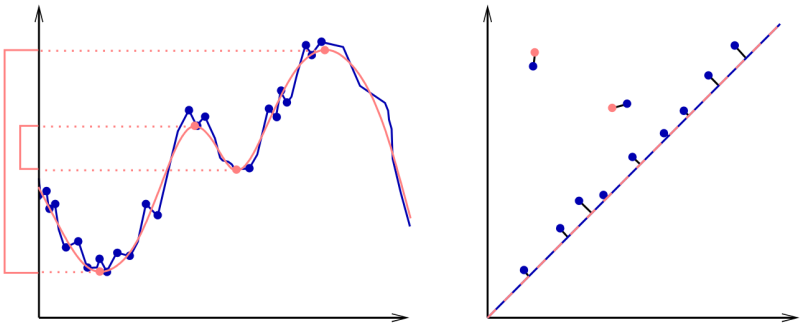
Proposition : L'infimum de la définition est en fait atteint, car, ayant un cardinal fini, les diagrammes de persistance sont localement finis.

Proposition : La distance Bottleneck satisfait l'inégalité triangulaire.

Théorème : Soit X un complexe simplicial compact, et soient f, $g : X \to \mathbb{R}$ deux fonctions continues. Soient $D(f)$ et $D(g)$ respectivement, leur diagramme de persistance induits par leurs filtrations des sous-niveaux. Soit $\|\cdot\|_\infty$ la norme infinie sur X. Alors :

$$d_B(D(f), D(g)) \leq \|f - g\|_\infty.$$

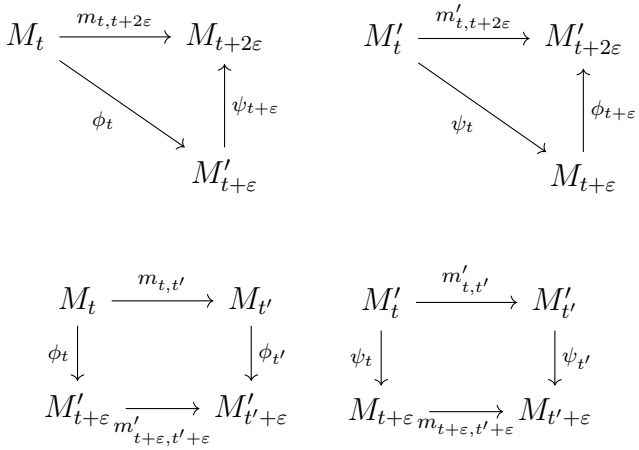
Exemple : Je reprends ici l'exemple de [12] :



Ici, on a deux fonctions continues, une en rose qui a deux minimums locaux, qui sont représentés sur le diagramme de droite. En bleu, on pourrait imaginer un échantillonnage de la fonction, dont les points ont été reliés. Une faible distance infinie entre les fonctions implique une faible distance entre les diagrammes pour la distance Bottleneck.

6.2 La distance d'entrelacement

Définition : Soient M et M' deux modules de persistance indexés sur $\mathbb{R}$. Soit $\varepsilon > 0$. Les modules M et M' sont ε-entrelacés si et seulement si il existe deux familles d'applications linéaires $\phi_t : M_t \to M'_{t+\varepsilon}$ et $\psi_t : M'_t \to M_{t+\varepsilon}$ telles que les diagrammes suivants commutent pour tout $t \leq t' \in \mathbb{R}$:



Remarque : Deux modules de persistance M et M' sont 0-entrelacés si et seulement si ils sont isomorphes.

Définition : *(Interleaving distance)* La distance d'entrelacement entre M et M', deux modules de persistance, est définie comme suivant :

$$d_i(M, M') = \inf\{\varepsilon \mid M \text{ et } M' \text{ sont entrelacés}\},$$

où lorsque $\{\varepsilon \mid M \text{ et } M' \text{ sont entrelacés}\}$ est vide, $d_i(M, M') = +\infty$.

Proposition : La distance d'entrelacement satisfait l'inégalité triangulaire.

6.3 Théorème d'isométrie

Théorème : Soient M et M' deux modules de persistance q-tame. On appelle $D(M)$ et $D(M')$ leurs diagrammes de persistance respectifs. Alors :

$$d_i(M, M') = d_B(D(M), D(M')).$$

Démonstration : *(Esquisse)* On va donner ici une idée de la preuve, et donner quelques théorèmes importants qui permettent de conclure. La preuve de (1) est donnée dans [11], section 5.6 et 5.7, et la preuve de (2) est donnée dans les sections 5.2 et 5.5.
Le théorème se décompose en deux propositions, d'abord le théorème de stabilité :

$$d_i(M, M') \geq d_B(D(M), D(M')). \tag{1}$$

Et le théorème de stabilité réciproque :

$$d_i(M, M') \leq d_B(D(M), D(M')). \tag{2}$$

On s'occupe d'abord de prouver le théorème de stabilité :

Pour commencer, donnons le théorème suivant qui implique (1) :
Théorème [1.1] : Soient M et M' deux modules de persistance q-tame qui sont δ-entrelacés, alors il existe une δ-correspondance entre $D(M)$ et $D(M')$.
En effet, si lorsqu'il existe un δ-entrelacement alors $d_i(M, M') \leq \delta \Rightarrow d_B(D(M), D(M')) \leq \delta$, et on a $d_i(M, M') \geq d_B(D(M), D(M'))$ en prenant l'infimum sur un tel δ.
On définit préalablement la mesure persistante :
Définition [1.2] : *(Mesure persistante)* La mesure persistante de M, un module de persistance est la fonction $\mu_M : [a, b] \times [c, d] \to \mathbb{N} \cup \{+\infty\}$, définie comme suivant :

$$\mu_M : ([a, b] \times [c, d]) = \dim \left[\frac{\mathrm{im}(m_{b,c}) \cap \ker(m_{c,d})}{\mathrm{im}(m_{a,c}) \cap \ker(m_{c,d})} \right].$$

La mesure de persistance compte le nombre de classes de persistance qui naissent dans [a,b] et meurent dans [c,d]. On définit le diagramme de persistance de la mesure μ_M :
Définition [1.3] : Le diagramme de persistance $D(\mu_M)$ de μ_M est l'unique ensemble tel que :
$\forall\ \mathcal{R}$ rectangle, $\quad \mu_M(\mathcal{R}) = \mathrm{Card}(D(\mu_M) \cap \mathcal{R})$.
De plus, on cette égalité :
Proposition [1.4] : Soit M un module q-tame, alors $D(M) = D(\mu_M)$.
Définition [1.5] : Un δ-épaississement de $R = [a, b] \times [c, d]$ est le rectangle $R^\delta = [a - \delta, b + \delta] \times [c - \delta, d + \delta]$.
On a alors ce résultat sur les mesures de persistance :
Proposition [1.6] : Soient M et M' sont deux modules de persistance δ-entrelacés. Soit R un rectangle et R^δ, son δ-épaississement. Alors, $\mu_M(R) \leq \mu_{M'}(R^\delta)$ et $\mu_{M'}(R) \leq \mu_M(R^\delta)$.
Ensuite, on énonce le lemme d'interpolation, qui va nous permettre de conclure :
Lemme [1.7] : *(Lemme d'interpolation)* Soient M et M' deux modules de persistance δ-entrelacés. Il existe alors une famille à un paramètre de modules de persistance $(M_x \mid x \in [0, \delta])$ telle que $M_0 = M$, $M_\delta = M'$, et M_x, M_y sont $|y - x|$-entrelacés pour tout $x, y \in [0, \delta]$. De plus, si M et M' sont q-tame, alors les $(\mathbb{U}_x)$ peuvent aussi être supposés q-tame.
Et enfin on énonce le théorème qui permet de conclure :
Théorème [1.8] : *(Admis)* Soit $(\mu_x \mid x \in [0, \delta])$ une famille à un paramètre de mesures finies sur un ouvert $\mathscr{D} \subseteq \mathbb{R}^2$. Supposons que pour tous $x, y \in [0, \delta]$, l'inégalité de [1.5] est

satisfaite :

$$\mu_x(R) \leq \mu_y(R^{|y-x|})$$

pour tout rectangle R dont le $|y-x|$-épaississement $R^{|y-x|}$ est un rectangle de $\mathscr{D}$. Alors il existe une δ-correspondance entre les diagrammes $D(\mu_0)$ et $D(\mu_\delta)$.
On notera que puisque M et M' sont q-tame, alors leurs mesures μ_M $\mu_{M'}$ sont finies.
Ainsi le lemme [1.7] permet de conclure avec le théorème [1.7], en prenant $\mu_0 = \mu_M$ et $\mu_\delta = \mu_{M'}$, et le théorème (1) est démontré. □

Pour (2), on va d'abord commencer par montrer une version moins forte du théorème :
Théorème [2.1] : Soient M et M' deux modules de persistance décomposable en somme directe de modules intervalles, alors $d_i(M, M') \leq d_B(D(M), D(M'))$.
On montre que lorsque il existe δ-correspondance entre $d(M)$ et $d(M')$, alors $d_i(M, M') \leq \delta$. Le résultat est obtenu en prenant l'infimum sur les δ.
Soit C une δ-correspondance entre les deux diagrammes. Alors on construit à partir de C une correspondance partielle entre chaque sommandes intervalles. On écrit M et M' comme suivant :

$$M = \bigoplus_{l \in L} M_l \qquad M' = \bigoplus_{l \in L} M'_l$$

Alors pour chaque (M_l, M'_l), il y a trois possibilités :
- Deux intervalles appariés.
- M_l est non-apparié (apparié à la diagonale) et $M'_l = 0$.
- M'_l est non-apparié et $M_l = 0$.

Si on est dans le premier cas, la proposition suivante permet de conclure :
Proposition [2.2] : Soient $M_l = M_I$ et $M'_l = M_{I'}$ avec $I = (a, b)$ et $I' = (c, d)$, alors $d_i(M, M') \leq d^\infty((a, b), (c, d))$.
Si on est dans le deuxième et troisième cas, alors la proposition suivante permet de conclure :
Proposition [2.3] : Soit $M_l = M_I$ avec $I = (a, b)$, alors $d_i(M, M') \leq \frac{1}{2}(b-a)$, où $M' = 0$.
On a de plus que $d^\infty((a, b), \Delta) = \frac{1}{2}(b - a)$, ce qui permet de conclure dans ce cas aussi.
Dans chaque cas nous avons donc : $d_i(M_l, M'_l) \leq \delta$, pour montrer que $d_i(M, M') \leq \delta$, on utilise la proposition suivante :
Proposition [2.4] : Si M et M' sont deux modules de persistance décomposables en modules intervalles tels que :

$$M = \bigoplus_{l \in L} M_l, \quad M' = \bigoplus_{l \in L} M'_l.$$

Alors $d_i(M, M') \leq \sup\left(d_i(M_l, M'_l) \mid \ell \in L\right)$.
Donc $d_i(M, M') \leq \delta$, et le théorème est démontré dans le cas décomposable. □

Dans le cas où M et M' sont seulement q-tame, on va approcher les modules par une version "lissée" qui sera décomposable.
Définition [3.1] : *(ε-lissage)* Soit M un module de persistance q-tame, le ε-lissage de M est le module de persistance M^ε défini comme tel :

$(M^\varepsilon)_t$ est l'image de $m_{t-\varepsilon,t+\varepsilon} : M_{t-\varepsilon} \to M_{t+\varepsilon}$.
Proposition [3.2] Si M est un module de persistance, alors $d_i(M, M^\varepsilon) \leq \varepsilon$.
Proposition [3.3] Si M est un module q-tame, alors $d_B(D(M), D(M^\varepsilon)) \leq \varepsilon$.
Et enfin pour conclure :
Proposition [3.4] Si M est un module q-tame, alors M^ε est décomposable en modules intervalles.
Ainsi, en alignant les propositions on obtient :

$$\begin{aligned} d_i(M, M') &\leq d_i(M^\varepsilon, M'^\varepsilon) + 2\varepsilon && \text{(par [3.2] et l'inégalité triangulaire pour } d_i\text{).} \\ &\leq d_B(D(M^\varepsilon), D(M'^\varepsilon)) + 2\varepsilon && \text{(par [2.1] et [3.4]).} \\ &\leq d_B(D(M), D(M')) + 4\varepsilon && \text{(par [3.3] et l'inégalité triangulaire pour } d_B\text{).} \end{aligned}$$

Ce qui conclut la preuve, car l'inégalité est vraie $\forall\ \varepsilon > 0$. □

7 Application et exemple : l'algorithme ToMATo

7.1 Problématique

Le problème que l'on se pose est le partitionnement des données, ou clustering ; on cherche à analyser des données sous forme de nuage de points par exemple et à en faire des grappes ou clusters, des groupes de points qui partagent des similarités. On va donc présenter un algorithme de clustering, appelé ToMATo ou 'Topological Mode Analysis Tool', qui utilise l'homologie persistante. Cette section a été écrite à partir de "Persistence-Based Clustering in Riemannian Manifolds" [13].

7.2 L'algorithme ToMATo

L'algorithme ToMATo est appliqué dans un cadre discret, à partir d'un nuage de points $L = \{x_1, ..., x_n\} \subset X$ où $|L| = n$ dans un espace euclidien X.
On lui donne en entrée un graphe simple dont les sommets sont les points de L, un paramètre de fusion $\tau \in \mathbb{R}^+ \cup \{+\infty\}$ et enfin une fonction $\tilde{f} : L \to \mathbb{R}$ qui associe à chaque point sa densité estimée.
L'algorithme va créer des clusters en passant en revue chaque sommet. Si le sommet n'a pas une proéminence assez haute, alors il va être fusionné avec un sommet plus proéminent. Le résultat est l'ensemble des sommets proéminents. Le paramètre τ contrôle ce que l'on considère comme suffisamment proéminent. Lorsque $\tau = +\infty$, la fusion a toujours lieu à l'intérieur de chaque composante connexe du graphe, et donc l'algorithme renvoie les composantes connexes du graphes.

Remarque : On peut aussi construire le graphe directement à partir de $\mathbf{D} \in \mathcal{M}_{n\times n}(\mathbb{R}^+)$, la matrice symétrique des distances d_{ij} entre deux points, et un paramètre δ qui lie deux points par une arête si et seulement si leur distance est inférieure à δ.

L'algorithme :
Étape 1, ToMATo Clustering : On commence par ordonner les points de L par ordre

décroissant de $\tilde{f}$. On va donc itérer de 1 à n, les sommets du graphe. Pour chaque sommet x_i, on le connecte par une arête à tout les voisins x_j tels que $\tilde{f}(x_j) \geq \tilde{f}(x_i)$. Si x_i à la plus haute densité parmi ses voisins selon $\tilde{f}$, alors il est considéré comme un pic. La collection de ses sommets plus des arêtes forme une forêt couvrante du graphe.
Définition : *(Forêt couvrante)* Un arbre couvrant d'un graphe non orienté et connexe est un arbre inclus dans ce graphe et qui connecte tous les sommets du graphe. Une forêt couvrante d'un graphe non connexe, est l'union des arbres couvrants de chaque composantes connexes du graphe.
Voici l'algorithme qui décrit ToMATo clustering :

Entrée: Vecteur $\tilde{f} \in \mathbb{R}^n$, matrice symétrique $D \in \mathbb{R}^{n \times n}$,
paramètres $\delta > 0$, $\tau > 0$
Sortie : L'ensemble des entrées e de $\mathcal{U}$ telles que $\tilde{f}(r(e)) \geq \tau$
Trier l'ensemble d'indices L tel que $\tilde{f}(x_1) \leq \tilde{f}(x_2) \leq \cdots \leq \tilde{f}(x_n)$
Initialiser la structure union-find $\mathcal{U}$
for $x_i \in \{x_n, \ldots, x_1\}$ **do**
  $S^+(x_i) = \{x_j \in Voisins(x_i) \mid \tilde{f}(x_j) \geq \tilde{f}(x_i)\}$
  if $S^+ = \emptyset$ **then**
    // x_i est un maximum local de $\tilde{f}$
    $g(x_i) \leftarrow$ null // $g(x_i)$ stocke le gradient approximatif en x_i
    Créer une nouvelle entrée dans $\mathcal{U}$ contenant l'arbre $\{x_i\}$
  else
    // x_i n'est pas un maximum local de $\tilde{f}$
    $g(x_i) \leftarrow \arg\max_{x_j \in S^+} \tilde{f}(x_j)$
    Attacher x_i à l'arbre contenant $g(x_i)$
    $\mathcal{U} \leftarrow$ Fusion($\tilde{f}, \mathcal{U}, i, S^+, \tau$)
  end
end

Algorithme 3: ToMATo Clustering

Étape 2, ToMATo Merge : Pour l'étape de fusion, on utilise une structure d' 'union find' où chaque entrée est une union d'arbres de la forêt couvrante. Soit e une union d'arbre, on appelle racine de e, notée $r(e)$ est le sommet x_i qui a la plus haute valeur de $\tilde{f}$. ToMATo repasse par tous les sommets x_i par ordre décroissant de $\tilde{f}$.

— Si x_i est un pic de $\tilde{f}$ dans G, c'est-à-dire la racine d'un certain arbre T_i, alors x_i crée une nouvelle entrée e_i dans la structure de données union-find, dans laquelle T_i est stocké.

— Si x_i n'est pas un pic et appartient donc à un certain arbre T_j, stocké dans une entrée existante e_j, alors on recherche des fusions potentielles de e_j avec d'autres entrées.

Plus précisément, en itérant sur les voisins x_k de x_i qui satisfont la condition $\tilde{f}(x_k) \leq \tilde{f}(x_i)$, on fusionne e_k dans e_j si :

$$\tilde{f}(r(e_k)) < \min\{\tilde{f}(r(e_j)), \tilde{f}(x_i) + \tau\}$$

autrement dit, si le pic $r(e_k)$ est plus bas que $r(e_j)$ et a une proéminence inférieure à τ.

Réciproquement, on fusionne e_j dans e_k si :

$$\tilde{f}(r(e_j)) < \min\{\tilde{f}(r(e_k)), \tilde{f}(x_i) + \tau\}.$$

Voici l'algorithme qui décrit ToMATo merge :

Entrée: Vecteur $f \in \mathbb{R}^n$, structure d'union-find $\mathcal{U}$, entier i, liste $L = \{x_1, \ldots, x_n\}$, paramètre $\tau > 0$
Sortie : Structure d'union-find $\mathcal{U}$ mise à jour

Soit e_i l'entrée de $\mathcal{U}$ contenant x_i. `// trouver les entrées de` $\mathcal{U}$ `dont les racines sont moins que` τ`-proéminentes, et les fusionner dans` e_i.
for $x_j \in \{x_1, \ldots, x_n\}$ **do**
  $e_j \leftarrow$ l'entrée de $\mathcal{U}$ contenant x_j
  if $e_j \neq e_i$ *et* $\tilde{f}(r(e_j)) - \tilde{f}(x_i) < \tau$ **then**
    Retirer e_j de $\mathcal{U}$ et l'attacher à e_i
  end
end
`// trouver l'entrée` $\bar{e}$ `de` $\mathcal{U}$ `dont la racine a la plus grande valeur`
$\bar{e} \leftarrow$ null
for $x_j \in \{x_1, \ldots, x_n\}$ **do**
  $e_j \leftarrow$ l'entrée de $\mathcal{U}$ contenant x_j
  if $\bar{e} =$ *null où* $\tilde{f}(r(e_j)) > \tilde{f}(r(\bar{e}))$ **then**
    $\bar{e} \leftarrow e_j$
  end
end
`// fusionner` e_i `dans` $\bar{e}$ `si la proéminence de la racine de` e_i `est inférieure à` τ
if $\bar{e} \neq e_i$ *et* $\tilde{f}(r(e_i) - \tilde{f}(x_i) < \tau$ **then**
  Retirer e_i de $\mathcal{U}$ et l'attacher à $\bar{e}$
end

Algorithme 4: ToMATo Merge

La sortie de ToMATo est l'ensemble des clusters fusionnés stockés dans les entrées de la structure de données union-find à la fin de la phase de fusion. En outre, ToMATo fournit les durées de vie de toutes les entrées créées au cours du processus, chacune étant représentée par un point dans le plan.

7.3 Lien avec l'homologie en degré 0

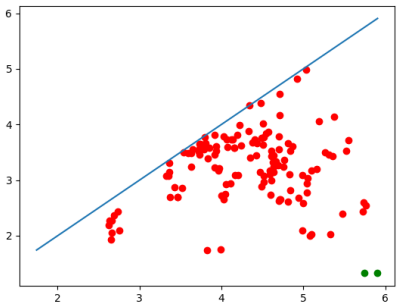
Définition : *(Graphe de Vietoris-Rips)* Soient L un nuage de point et δ un paramètre positif. Alors le graphe de Vietoris-Rips $\mathcal{R}_\delta(L)$ est le complexe de Vietoris-Rips $\mathbb{VR}^\delta(L)$, sans les simplexes de dimension > 1.

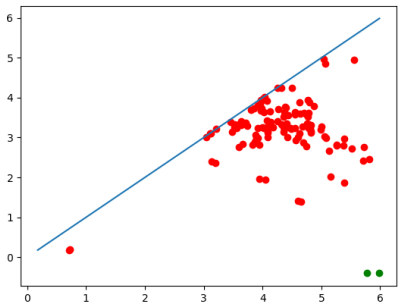
Définition : Soit $f : X \to \mathbb{R}$ une fonction de densité, et soit α un paramètre réel. Alors $L^\alpha = L \cap F^\alpha$, où F^α est l'ensemble des sur-niveaux de f, $F^\alpha = ([\alpha, +\infty[)$.

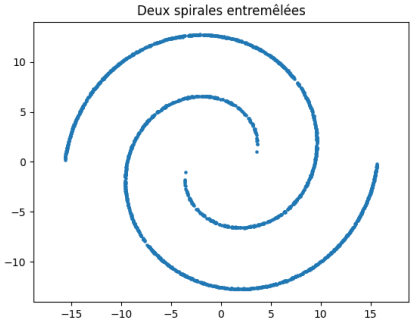
Définition : *(Filtration des sur-niveaux de Vietoris-Rips)* La filtration des sur-niveaux de Vietoris-Rips est la famille de graphes de Vietoris-Rips $\mathcal{R}^f_\delta(L)$ définie comme telle : $\mathcal{R}^f_\delta(L) = \{\mathcal{R}_\delta(L^\delta)\}_{\alpha \in \mathbb{R}}$.

Théorème : *(ToMATo et l'homologie en degré 0)* Soient $\delta > 0$, $\tilde{f} : L \to \mathbb{R}$, et $\mathbf{D} \in \mathcal{M}_{n\times n}(\mathbb{R}^+)$. Alors lorsque que l'on applique ToMATo avec $\tau = +\infty$, les durées de vie de toutes les entrées forment le diagramme de persistance de l'homologie persistante en degré 0 de la filtration $\mathcal{R}_\delta^f(L)$.

Pour terminer la section, nous allons présenter l'exemple des spirales imbriquées, tiré de [13]. Ici des spirales imbriquées ont été générées par python et on affiche ensuite leur diagramme de persistance pour un τ optimal, puis pour $\tau = +\infty$ (les points en vert représentent les clusters finaux) :







8 Conclusion

Ce travail a permis d'explorer les fondements de l'analyse topologique des données et de mieux comprendre ses outils, notamment l'homologie persistante. Il m'a offert une première expérience de recherche en autonomie, constituant une base pour la suite de mon parcours.

Au-delà des exemples étudiés, la TDA trouve de nombreuses applications dans des domaines variés comme la biologie, l'intelligence artificielle et ouvre la porte à de nouvelles manières d'envisager certains problèmes d'analyse de données.

Bibliographie

[1] Frédéric Chazal, David Cohen-Steiner, Leonidas J. Guibas, Facundo Mémoli, Steve Oudot, "Gromov-Hausdorff Stable Signatures for Shapes using Persistence" ,The Eurographics Association and Blackwell Publishing Ltd, 2009.

[2] Pierre Guillot, *Leçons sur l'homologie et le groupe fondamental*, Collection Société Mathématique de France, Chapitre 7 et 8, 2022.

[3] Omer Bobrowski, Matthew Kahle, *Topology of random geometric complexes : a survey*, Journal of Applied and Computational Topology, 2018

[4] «Homologie des surfaces compactes orientables», URL, Analysis situs.

[5] Vincent Humilière, Mathieu Carrière, Steve Oudot, «Analyse topologique des données», Notes de cours des journées X-UPS, URL, 2024.

[6] Herbert Edelsbrunner, John Harer, *Computational Topology : An introduction*, American Mathematical Society, Chapitre 7, 2010.

[7] William Crawley-Boevey, "Decomposition of pointwise finite-dimensional persistence module", Journal of algebra and its application, Vol 14, 2015.

[8] Steve Oudot, "Topological Persistence", URL, Notes de cours.

[9] Frédéric Chazal, Vin de Silva, Steve Oudot, "Persistence stability for geometric complexes", Geometriae Dedicata, Springer, page 13, 2013.

[10] Tamal Krishna Dey, Yusu Wang *Computational Topology for Data Analysis*, Cambridge University Press, 2021.

[11] Frédéric Chazal, Vin de Silva, Marc Glisse, Steve Oudot, *The Structure and Stability of Persistence Modules*, Springer, 2016.

[12] David Cohen-Steiner, Herbert Edelsbrunner, John Harer, "Stability of Persistence Diagrams", Discrete and Computational Geometry, Springer, page 7, 2005.

[13] Frédéric Chazal, Steve Oudot, Primoz Skraba, Leonidas J. Guibas, "Persistence-Based Clustering in Riemannian Manifolds", Journal of the ACM, Vol 60, 2011.

[14] Daniel Hostettler, "Topological Clustering Algorithm ToMATo", Bachelor Thesis, 2024.